

# CUELO 하네스 벤치마크

같은 AI 모델에게 같은 코딩 과제를 주고, 그 AI를 부리는 "도구"만 바꿔 비교했다. CUELO(우리가 만든 도구), Claude Code, Codex 세 가지다. 정답 여부는 AI가 미리 볼 수 없는 채점 테스트로 판정했고, 모든 값은 여러 번 돌린 결과의 가운데 값이다.

## 결론 먼저

초록 ▲는 CUELO가 유리, 빨강 ▼는 불리, 회색 =는 비슷함(차이 5% 미만)이다. 비교 상대는 같은 AI를 쓴 Claude Code다.

- 어려운 과제 · 안전 장치 새로 만들고 실제로 연결하기 — 시간 ▲ 31% 더 빠름 · 사용량 ▼ 5% 더 씀 · 요금 = 비슷함 · 정답률은 같음
- 묶음 과제(2개) · 서로 다른 수정 두 개 한 번에 — 시간 ▲ 10% 더 빠름 · 사용량 ▼ 20% 더 씀 · 요금 ▼ 16% 더 비쌈 · 정답률은 같음
- 묶음 과제(3개) · 서로 다른 수정 세 개 한 번에 — 시간 = 비슷함 · 사용량 ▼ 35% 더 씀 · 요금 ▼ 26% 더 비쌈 · 정답률은 같음
- 대규모 과제 · 스프레드시트 계산 엔진 새로 만들기 — 시간 ▲ 10% 더 빠름 · 사용량 = 비슷함 · 요금 ▲ 8% 더 싼 · 맞힌 테스트 비율 CUELO 98.3% · Claude Code 97.5%
- 초대형 과제 · 서로 독립인 패키지 6개 새로 만들기 — 시간 ▼ 53% 더 느림 · 사용량 ▲ 24% 덜 씀 · 요금 ▲ 19% 더 싼 · 정답률은 같음

어려운 과제 · 안전 장치 새로 만들고 실제로 연결하기

한 줄 요약: 같은 AI(Opus 5.5)를 쓸 때 CUELO는 Claude Code보다 시간 ▲ 31% 더 빠름 , AI 사용량 ▼ 5% 더 싼 , API 환산 요금 = 비슷함 , 정답률은 같음.

| 순위 | 도구 · AI 모델                    | 정답 횟수        | 걸린 시간 (Claude Code 대비) | AI 사용량 (Claude Code 대비) | API 환산 요금 (Claude Code 대비) |
|----|-------------------------------|--------------|------------------------|-------------------------|----------------------------|
| 1  | ● CUELO · Opus 5.5 high       | 6/6<br>전부 정답 | 7분 47초<br>▲ 31% 빠름     | 782K<br>▼ 5% 많음         | \$2.24<br>= 비슷함            |
| 2  | ● Claude Code · Opus 5.5 high | 3/3<br>전부 정답 | 11분 19초                | 745K                    | \$2.26                     |
| 3  | ● Codex · Daybreak Blue high  | 3/3<br>전부 정답 | 21분 40초<br>▼ 91% 느림    | 961K<br>▼ 29% 많음        | \$3.65<br>▼ 62% 비쌌         |

| 정답률 — 길수록 좋음            |                  | 걸린 시간 — 짧을수록 좋음         |                     | AI 사용량 — 짧을수록 좋음        |                  |
|-------------------------|------------------|-------------------------|---------------------|-------------------------|------------------|
| CUELO · Opus 5.5 high   | <div></div> 100% | CUELO · Opus 5.5 high   | <div></div> 7분 47초  | CUELO · Opus 5.5 high   | <div></div> 782K |
| Claude Code · Opus ...  | <div></div> 100% | Claude Code · Opus ...  | <div></div> 11분 19초 | Claude Code · Opus ...  | <div></div> 745K |
| Codex · Daybreak Blu... | <div></div> 100% | Codex · Daybreak Blu... | <div></div> 21분 40초 | Codex · Daybreak Blu... | <div></div> 961K |

묶음 과제(2개) · 서로 다른 수정 두 개 한 번에

한 줄 요약: 같은 AI(Opus 5.5)를 쓸 때 CUELO는 Claude Code보다 시간 ▲ 10% 더 빠름 , AI 사용량 ▼ 20% 더 썸 , API 환산 요금 ▼ 16% 더 비쌘 , 정답률은 같음.

| 순위 | 도구 · AI 모델                    | 정답 횟수        | 걸린 시간 (Claude Code 대비) | AI 사용량 (Claude Code 대비) | API 환산 요금 (Claude Code 대비) |
|----|-------------------------------|--------------|------------------------|-------------------------|----------------------------|
| 1  | ● CUELO · Opus 5.5 high       | 3/3<br>전부 정답 | 1분 53초<br>▲ 10% 빠름     | 281K<br>▼ 20% 많음        | \$0.98<br>▼ 16% 비쌘         |
| 2  | ● Claude Code · Opus 5.5 high | 3/3<br>전부 정답 | 2분 5초                  | 234K                    | \$0.84                     |
| 3  | ● Codex · Daybreak Blue high  | 3/3<br>전부 정답 | 4분 4초<br>▼ 95% 느림      | 240K<br>= 비슷함           | \$0.84<br>= 비슷함            |

정답률 — 길수록 좋음

|                         |             |      |
|-------------------------|-------------|------|
| CUELO · Opus 5.5 high   | <div></div> | 100% |
| Claude Code · Opus ...  | <div></div> | 100% |
| Codex · Daybreak Blu... | <div></div> | 100% |

걸린 시간 — 짧을수록 좋음

|                         |             |        |
|-------------------------|-------------|--------|
| CUELO · Opus 5.5 high   | <div></div> | 1분 53초 |
| Claude Code · Opus ...  | <div></div> | 2분 5초  |
| Codex · Daybreak Blu... | <div></div> | 4분 4초  |

AI 사용량 — 짧을수록 좋음


|                         |             |      |
|-------------------------|-------------|------|
| CUELO · Opus 5.5 high   | <div></div> | 281K |
| Claude Code · Opus ...  | <div></div> | 234K |
| Codex · Daybreak Blu... | <div></div> | 240K |

## 묶음 과제(3개) · 서로 다른 수정 세 개 한 번에

한 줄 요약: 같은 AI(Opus 5.5)를 쓸 때 CUELO는 Claude Code보다 시간 = 비슷함 , AI 사용량 ▼ 35% 더 싼 , API 환산 요금 ▼ 26% 더 비쌘 , 정답률은 같음.

| 순위 | 도구 · AI 모델                    | 정답 횟수        | 걸린 시간 (Claude Code 대비) | AI 사용량 (Claude Code 대비) | API 환산 요금 (Claude Code 대비) |
|----|-------------------------------|--------------|------------------------|-------------------------|----------------------------|
| 1  | ● CUELO · Opus 5.5 high       | 3/3<br>전부 정답 | 6분 59초<br>= 비슷함        | 1.08M<br>▼ 35% 많음       | \$3.12<br>▼ 26% 비쌘         |
| 2  | ● Claude Code · Opus 5.5 high | 3/3<br>전부 정답 | 7분 11초                 | 805K                    | \$2.48                     |
| 3  | ● Codex · Daybreak Blue high  | 2/3<br>일부 실패 | 7분 42초<br>▼ 7% 느림      | 619K<br>▲ 23% 적음        | \$2.25<br>▲ 9% 싼           |

### 정답률 — 길수록 좋음




100%

100%

67%

### 걸린 시간 — 짧을수록 좋음




100%

100%

67%

### AI 사용량 — 짧을수록 좋음



100%

100%

67%

1.08M


805K

619K

## 보통 과제 · 기존 기능 하나 고치기

| 순위 | 도구 · AI 모델                  | 정답 횟수        | 걸린 시간 (Claude Code 대비) | AI 사용량 (Claude Code 대비) | API 환산 요금 (Claude Code 대비) |
|----|-----------------------------|--------------|------------------------|-------------------------|----------------------------|
| 1  | ● CUELO · Opus 5.5 medium   | 3/3<br>전부 정답 | 51초                    | 119K                    | \$0.47                     |
| 2  | ● Codex · GPT-6 Luna medium | 3/3<br>전부 정답 | 1분 2초                  | 56K                     | \$0.01                     |


### 정답률 — 길수록 좋음



100%

100%


### 걸린 시간 — 짧을수록 좋음



100%

100%

### AI 사용량 — 짧을수록 좋음



100%

100%

119K

56K

대규모 과제 · 스프레드시트 계산 엔진 새로 만들기

**한 줄 요약:** 같은 AI(Opus 5.5)를 쓸 때 CUELO는 Claude Code보다 시간 ▲ 10% 더 빠름 , AI 사용량 = 비슷함 , API 환산 요금 ▲ 8% 더 싼 , 맞힌 테스트 비율 CUELO 98.3% · Claude Code 97.5%.

| 순위 | 도구 · AI 모델                                         | 정답 횟수               | 걸린 시간 (Claude Code 대비) | AI 사용량 (Claude Code 대비) | API 환산 요금 (Claude Code 대비) |
|----|----------------------------------------------------|---------------------|------------------------|-------------------------|----------------------------|
| 1  | <div><div></div> Codex · Daybreak Blue high</div>  | 0/2<br>테스트 99.3% 맞힘 | 12분 31초<br>▼ 28% 느림    | 462K<br>▲ 34% 적음        | \$1.40<br>▲ 33% 싼          |
| 2  | <div><div></div> CUELO · Opus 5.5 high</div>       | 0/2<br>테스트 98.3% 맞힘 | 8분 47초<br>▲ 10% 빠름     | 666K<br>= 비슷함           | \$1.93<br>▲ 8% 싼           |
| 3  | <div><div></div> Claude Code · Opus 5.5 high</div> | 0/2<br>테스트 97.5% 맞힘 | 9분 48초                 | 700K                    | \$2.10                     |

맞힌 테스트 비율 — 길수록 좋음 (모두 만점은 못 받음)

|                             |             |       |
|-----------------------------|-------------|-------|
| Codex · Daybreak Blue high  | <div></div> | 99.3% |
| CUELO · Opus 5.5 high       | <div></div> | 98.3% |
| Claude Code · Opus 5.5 high | <div></div> | 97.5% |

걸린 시간 — 짧을수록 좋음

|                             |             |         |
|-----------------------------|-------------|---------|
| Codex · Daybreak Blue high  | <div></div> | 12분 31초 |
| CUELO · Opus 5.5 high       | <div></div> | 8분 47초  |
| Claude Code · Opus 5.5 high | <div></div> | 9분 48초  |

AI 사용량 — 짧을수록 좋음

|                             |             |      |
|-----------------------------|-------------|------|
| Codex · Daybreak Blue high  | <div></div> | 462K |
| CUELO · Opus 5.5 high       | <div></div> | 666K |
| Claude Code · Opus 5.5 high | <div></div> | 700K |

초대형 과제 · 서로 독립인 패키지 6개 새로 만들기

한 줄 요약: 같은 AI(Opus 5.5)를 쓸 때 CUELO는 Claude Code보다 시간 ▼ 53% 더 느림 , AI 사용량 ▲ 24% 덜 씀 , API 환산 요금 ▲ 19% 더 싼 , 정답률은 같음.

| 순위 | 도구 · AI 모델                    | 정답 횟수               | 걸린 시간 (Claude Code 대비) | AI 사용량 (Claude Code 대비) | API 환산 요금 (Claude Code 대비) |
|----|-------------------------------|---------------------|------------------------|-------------------------|----------------------------|
| 1  | ● CUELO · Opus 5.5 high       | 0/1<br>테스트 99.8% 맞힘 | 25분 2초<br>▼ 53% 느림     | 2.43M<br>▲ 24% 적음       | \$7.10<br>▲ 19% 싼          |
| 2  | ● Claude Code · Opus 5.5 high | 0/1<br>테스트 99.5% 맞힘 | 16분 24초                | 3.21M                   | \$8.73                     |
| 3  | ● Codex · Daybreak Blue high  | 0/1<br>테스트 98.5% 맞힘 | 25분 54초<br>▼ 58% 느림    | 1.27M<br>▲ 60% 적음       | \$4.31<br>▲ 51% 싼          |

맞힌 테스트 비율 — 길수록 좋음 (모두 만점은 못 받음)

|                         |             |       |
|-------------------------|-------------|-------|
| CUELO · Opus 5.5 high   | <div></div> | 99.8% |
| Claude Code · Opus ...  | <div></div> | 99.5% |
| Codex · Daybreak Blu... | <div></div> | 98.5% |

걸린 시간 — 짧을수록 좋음

|                         |             |         |
|-------------------------|-------------|---------|
| CUELO · Opus 5.5 high   | <div></div> | 25분 2초  |
| Claude Code · Opus ...  | <div></div> | 16분 24초 |
| Codex · Daybreak Blu... | <div></div> | 25분 54초 |

AI 사용량 — 짧을수록 좋음

|                         |             |       |
|-------------------------|-------------|-------|
| CUELO · Opus 5.5 high   | <div></div> | 2.43M |
| Claude Code · Opus ...  | <div></div> | 3.21M |
| Codex · Daybreak Blu... | <div></div> | 1.27M |

## 메인 혼자 할 때 vs 전부 나눠 맡길 때

**무엇을 비교했나:** "메인 혼자"는 메인 AI가 하위 AI 없이 직접 구현한 경우다. 세 도구 모두 기록상 하위 AI를 쓰지 않았다(CUELO 대규모 6종 과제는 위임을 시도했으나 당시 설정 오류로 하위 AI 후보를 받지 못해 혼자 했다). "전부 위임"은 직접 고치지 말고 하위 AI(Maker-서브에이전트)에게 맡기라고 강제한 경우다. 비교 칩은 같은 도구의 메인 혼자 결과 대비다. 하위 AI 모델이 다르면 토큰 단가가 수십 배 다르므로 "AI 사용량"이 아니라 "API 환산 요금"으로 비교한다. Codex는 하위 AI의 사용량이 기록에 따로 나오지 않아 사용량·요금이 실제보다 적게 잡혔을 수 있다. Claude Code는 실행 기록에 중간 도구 호출이 남지 않아 실제 위임 여부를 확인하지 못했다. Codex 보통 과제 위임 2회는 하위 AI 생성 오류(도구 자체 문제)로 코드를 전혀 고치지 못해 표에서 뺐다.

## 어려운 과제 · 안전 장치 새로 만들고 실제로 연결하기

| 도구 · 메인 모델                    | 방식                       | 정답                            | 걸린 시간 (메인 혼자 대비)                  | AI 사용량 (메인 혼자 대비)               | API 환산 요금 (메인 혼자 대비)             |
|-------------------------------|--------------------------|-------------------------------|-----------------------------------|---------------------------------|----------------------------------|
| ● CUELO · Opus 5.5 high       | 메인 혼자                    | 6/6 <span>전부 정답</span>        | 7분 47초                            | 782K                            | \$2.24                           |
| ● Claude Code · Opus 5.5 high | 메인 혼자                    | 3/3 <span>전부 정답</span>        | 11분 19초                           | 745K                            | \$2.26                           |
| ● Codex · Daybreak Blue high  | 메인 혼자                    | 3/3 <span>전부 정답</span>        | 21분 40초                           | 961K                            | \$3.65                           |
| ● CUELO · Opus 5.5 high       | 전부 위임 · GPT-6 Luna Maker | 0/1 <span>테스트 99.5% 맞힘</span> | 29분 59초<br><span>▼ 286% 느림</span> | 2.97M<br><span>▼ 279% 많음</span> | \$2.90<br><span>▼ 29% 비쌘</span>  |
| ● Claude Code · Opus 5.5 high | 전부 위임 · 자체 서브에이전트        | 1/2 <span>일부 실패</span>        | 21분 55초<br><span>▼ 94% 느림</span>  | 1.88M<br><span>▼ 152% 많음</span> | \$4.88<br><span>▼ 116% 비쌘</span> |
| ● Codex · Daybreak Blue high  | 전부 위임 · 자체 서브에이전트        | 2/2 <span>전부 정답</span>        | 20분 2초<br><span>▲ 8% 빠름</span>    | 341K<br><span>▲ 65% 적음</span>   | \$1.23<br><span>▲ 66% 쌘</span>   |
| ● CUELO · Opus 5.5 high       | 전부 위임 · Opus 5.5 Maker   | 2/2 <span>전부 정답</span>        | 11분 37초<br><span>▼ 49% 느림</span>  | 1.50M<br><span>▼ 92% 많음</span>  | \$4.47<br><span>▼ 99% 비쌘</span>  |

보통 과제 · 기존 기능 하나 고치기

| 도구 · 메인 모델                      | 방식                       | 정답           | 걸린 시간 (메인 혼자 대비)    | AI 사용량 (메인 혼자 대비) | API 환산 요금 (메인 혼자 대비) |
|---------------------------------|--------------------------|--------------|---------------------|-------------------|----------------------|
| ● CUELO · Opus 5.5 medium       | 메인 혼자                    | 3/3<br>전부 정답 | 51초                 | 119K              | \$0.47               |
| ● Codex · GPT-6 Luna medium     | 메인 혼자                    | 3/3<br>전부 정답 | 1분 2초               | 56K               | \$0.01               |
| ● CUELO · Opus 5.5 medium       | 전부 위임 · GPT-6 Luna Maker | 2/2<br>전부 정답 | 4분 29초<br>▼ 426% 느림 | 488K<br>▼ 310% 많음 | \$1.13<br>▼ 142% 비쌌  |
| ● Claude Code · Opus 5.5 medium | 전부 위임 · 자체 서버에 이전트       | 2/2<br>전부 정답 | 1분 37초              | 147K              | \$0.46               |
| ● CUELO · Opus 5.5 medium       | 전부 위임 · Opus 5.5 Maker   | 2/2<br>전부 정답 | 3분 51초<br>▼ 352% 느림 | 586K<br>▼ 393% 많음 | \$2.05<br>▼ 341% 비쌌  |

대규모 과제 · 스프레드시트 계산 엔진 새로 만들기

| 도구 · 메인 모델                    | 방식                 | 정답                  | 걸린 시간 (메인 혼자 대비)    | AI 사용량 (메인 혼자 대비) | API 환산 요금 (메인 혼자 대비) |
|-------------------------------|--------------------|---------------------|---------------------|-------------------|----------------------|
| ● Claude Code · Opus 5.5 high | 메인 혼자              | 0/2<br>테스트 97.5% 맞힘 | 9분 48초              | 700K              | \$2.10               |
| ● Codex · Daybreak Blue high  | 메인 혼자              | 0/2<br>테스트 99.3% 맞힘 | 12분 31초             | 462K              | \$1.40               |
| ● CUELO · Opus 5.5 high       | 메인 혼자              | 0/2<br>테스트 98.3% 맞힘 | 8분 47초              | 666K              | \$1.93               |
| ● Claude Code · Opus 5.5 high | 전부 위임 · 자체 서버에 이전트 | 0/2<br>테스트 98.3% 맞힘 | 12분 18초<br>▼ 25% 느림 | 861K<br>▼ 23% 많음  | \$2.45<br>▼ 17% 비쌌   |
| ● Codex · Daybreak Blue high  | 전부 위임 · 자체 서버에 이전트 | 0/2<br>테스트 99.0% 맞힘 | 20분 29초<br>▼ 64% 느림 | 369K<br>▲ 20% 적음  | \$1.36 = 비슷함         |

| 도구 · 메인 모델              | 방식                     | 정답                  | 걸린 시간 (메인 혼자 대비)     | AI 사용량 (메인 혼자 대비)  | API 환산 요금 (메인 혼자 대비) |
|-------------------------|------------------------|---------------------|----------------------|--------------------|----------------------|
| ● CUELO · Opus 5.5 high | 전부 위임 · Opus 5.5 Maker | 0/2<br>테스트 97.2% 맞힘 | 20분 11초<br>▼ 130% 느림 | 2.86M<br>▼ 329% 많음 | \$8.54<br>▼ 344% 비쌌  |

## 묶음 과제(3개) · 서로 다른 수정 세 개 한 번에

| 도구 · 메인 모델                    | 방식                               | 정답           | 걸린 시간 (메인 혼자 대비)     | AI 사용량 (메인 혼자 대비)  | API 환산 요금 (메인 혼자 대비) |
|-------------------------------|----------------------------------|--------------|----------------------|--------------------|----------------------|
| ● Claude Code · Opus 5.5 high | 메인 혼자                            | 3/3<br>전부 정답 | 7분 11초               | 805K               | \$2.48               |
| ● Codex · Daybreak Blue high  | 메인 혼자                            | 2/3<br>일부 실패 | 7분 42초               | 619K               | \$2.25               |
| ● CUELO · Opus 5.5 high       | 메인 혼자                            | 3/3<br>전부 정답 | 6분 59초               | 1.08M              | \$3.12               |
| ● CUELO · Opus 5.5 high       | 전부 위임 · Daybreak Blue Maker      | 1/2<br>일부 실패 | 20분 54초<br>▼ 199% 느림 | 2.63M<br>▼ 142% 많음 | \$8.30<br>▼ 166% 비쌌  |
| ● CUELO · Opus 5.5 high       | 전부 위임 · DeepSeek 4.1 Flash Maker | 2/2<br>전부 정답 | 27분 27초<br>▼ 293% 느림 | 5.22M<br>▼ 381% 많음 | \$5.29<br>▼ 69% 비쌌   |
| ● CUELO · Opus 5.5 high       | 전부 위임 · GPT-6 Luna Maker         | 2/2<br>전부 정답 | 25분 4초<br>▼ 259% 느림  | 2.76M<br>▼ 154% 많음 | \$3.37<br>▼ 8% 비쌌    |
| ● CUELO · Opus 5.5 high       | 전부 위임 · Opus 5.5 Maker           | 2/2<br>전부 정답 | 9분 40초<br>▼ 38% 느림   | 2.07M<br>▼ 91% 많음  | \$6.81<br>▼ 118% 비쌌  |

## 초대형 과제 · 서로 독립인 패키지 6개 새로 만들기

| 도구 · 메인 모델                    | 방식    | 정답                  | 걸린 시간 (메인 혼자 대비) | AI 사용량 (메인 혼자 대비) | API 환산 요금 (메인 혼자 대비) |
|-------------------------------|-------|---------------------|------------------|-------------------|----------------------|
| ● Claude Code · Opus 5.5 high | 메인 혼자 | 0/1<br>테스트 99.5% 맞힘 | 16분 24초          | 3.21M             | \$8.73               |

| 도구 · 메인 모델                    | 방식                     | 정답                  | 걸린 시간 (메인 혼자 대비)    | AI 사용량 (메인 혼자 대비)  | API 환산 요금 (메인 혼자 대비) |
|-------------------------------|------------------------|---------------------|---------------------|--------------------|----------------------|
| ● Codex · Daybreak Blue high  | 메인 혼자                  | 0/1<br>테스트 98.5% 맞힘 | 25분 54초             | 1.27M              | \$4.31               |
| ● CUELO · Opus 5.5 high       | 메인 혼자                  | 0/1<br>테스트 99.8% 맞힘 | 25분 2초              | 2.43M              | \$7.10               |
| ● Claude Code · Opus 5.5 high | 전부 위임 · 자체 서버에 이전트     | 0/1<br>테스트 99.4% 맞힘 | 23분 45초<br>▼ 45% 느림 | 4.47M<br>▼ 39% 많음  | \$12.20<br>▼ 40% 비쌈  |
| ● Codex · Daybreak Blue high  | 전부 위임 · 자체 서버에 이전트     | 0/1<br>테스트 99.3% 맞힘 | 22분 57초<br>▲ 11% 빠름 | 578K<br>▲ 55% 적음   | \$2.14<br>▲ 50% 쌈    |
| ● CUELO · Opus 5.5 high       | 전부 위임 · Opus 5.5 Maker | 0/1<br>테스트 99.3% 맞힘 | 25분 39초<br>= 비슷함    | 5.08M<br>▼ 109% 많음 | \$16.01<br>▼ 126% 비쌈 |

## 용어 풀이

### AI 사용량

AI가 읽고 쓴 글자 양(토큰)을 요금 비중으로 환산한 값이다. 새로 읽은 양 +  $0.1 \times$  이미 기억해 둔 부분 다시 읽기 +  $1.25 \times$  기억해 두기 +  $8 \times$  AI가 쓴 양. 비율은 가정값이고 모든 모델에 같게 적용한다. 같은 모델끼리는 적을수록 싸지만, 모델이 다르면 토큰 단가가 수십 배 달라 이 값으로 돈을 비교할 수 없다(아래 API 환산 요금을 본다). 위임한 경우 하위 AI가 쓴 양도 합친다.

### 맞힌 테스트 (예: 958/960)

AI가 만든 프로그램을 검사하는 자동 채점 문항 수다. 문항 하나는 "이 입력을 넣으면 이 답이 나와야 한다" 같은 확인 한 가지다. 예를 들어 초대형 과제에는 문항이 960개 있고, 958/960은 960개 중 958개를 통과했다는 뜻이다. 문항은 AI가 작업 중에 볼 수 없게 숨겨 두었다가 끝난 뒤에만 돌렸다. 시험지를 미리 보지 못하게 한 채점이다.

### 정답 횟수

같은 과제를 여러 번(기본 3회, 위임·대규모는 2회) 돌려 채점 테스트를 모두 통과한 횟수.

### Maker·서브에이전트

메인 AI가 일을 나눠 맡기는 하위 AI.

### high / medium

AI에게 생각을 얼마나 깊게 시키는지 설정. high가 더 깊고 느리다.

### API 환산 요금

기록된 토큰을 각 회사 공식 API 단가(1M 토큰당 표준 요금)로 곱한 값이다. 측정은 월정액 구독으로 돌렸으므로 실제 청구액이 아니라 "API로 냈다면 얼마인가"다. 모델마다 따로 계산해 합친다. 단가 출처(2026-09-25 확인): [Anthropic Opus 5.5](#)(입력 \$4 · 출력 \$20 · 캐시 읽기 \$0.20), [OpenAI 가격표](#)(GPT-6 Luna 입력 \$0.10 · 출력 \$0.50, Daybreak Blue = gpt-5.6-sol 입력 \$4 · 출력 \$20), [DeepSeek 가격표](#)(V4.1 Flash 입력 \$0.15 · 출력 \$0.60, 혼잡 시간 2배). Claude Code는 도구가 직접 남긴 요금을 쓴다. Codex는 요청별 기록이 없어 긴 문맥 할증을 넣지 못했고 하위 AI 몫이 빠질 수 있어 실제보다 낮을 수 있다.

## 자세히 보기 (측정 방법)

순위는 정답률 → 시간 → 사용량 순이다. 돈 비교는 API 환산 요금 열을 본다. 그래프의 가는 선은 최소~최대 범위다. CUELO 시간은 세션 유틸 대기를 뺀 실제 작업 시간이다. 과제 폴더의 규칙 파일은 모든 도구에서 숨겨 같은 조건을 맞췄다. 총 76회 실행.