

CUELO 하네스 벤치마크

같은 AI 모델에게 같은 코딩 과제를 주고, 그 AI를 부리는 "도구"만 바꿔 비교했다. CUELO(우리가 만든 도구), Claude Code, Codex 세 가지다. 정답 여부는 AI가 미리 볼 수 없는 채점 테스트로 판정했고, 모든 값은 여러 번 돌린 결과의 가운데 값이다.

결론 먼저

초록 ▲는 CUELO가 유리, 빨강 ▼는 불리, 회색 =는 비슷함(차이 5% 미만)이다. 비교 상대는 같은 AI를 쓴 Claude Code다.

- 어려운 과제 · 안전 장치 새로 만들고 실제로 연결하기 — 시간 ▲ 31% 더 빠름 · 사용량 ▼ 5% 더 씀 · 정답률은 같음
- 묶음 과제(2개) · 서로 다른 수정 두 개 한 번에 — 시간 ▲ 10% 더 빠름 · 사용량 ▼ 20% 더 씀 · 정답률은 같음
- 묶음 과제(3개) · 서로 다른 수정 세 개 한 번에 — 시간 = 비슷함 · 사용량 ▼ 35% 더 씀 · 정답률은 같음
- 대규모 과제 · 스프레드시트 계산 엔진 새로 만들기 — 시간 ▲ 10% 더 빠름 · 사용량 = 비슷함 · 맞힌 테스트 비율 CUELO 98.3% · Claude Code 97.5%
- 초대형 과제 · 서로 독립인 패키지 6개 새로 만들기 — 시간 ▼ 53% 더 느림 · 사용량 ▲ 24% 덜 씀 · 정답률은 같음

어려운 과제 · 안전 장치 새로 만들고 실제로 연결하기

한 줄 요약: 같은 AI(Opus 5.5)를 쓸 때 CUELO는 Claude Code보다 시간 ▲ 31% 더 빠름, AI 사용량 ▼ 5% 더 썸, 정답률은 같음.

순위	도구 · AI 모델	정답 횟수	걸린 시간 (Claude Code 대비)	AI 사용량 (Claude Code 대비)	실제 요금
1	● CUELO · Opus 5.5 high	6/6 전부 정답	7분 47초 ▲ 31% 빠름	782K ▼ 5% 많음	\$2.24
2	● Claude Code · Opus 5.5 high	3/3 전부 정답	11분 19초	745K	\$2.26
3	● Codex · Daybreak Blue high	3/3 전부 정답	21분 40초 ▼ 91% 느림	961K ▼ 29% 많음	구독(정액)

정답률 — 길수록 좋음		걸린 시간 — 짧을수록 좋음		AI 사용량 — 짧을수록 좋음	
CUELO · Opus 5.5 high	100%	CUELO · Opus 5.5 high	7분 47초	CUELO · Opus 5.5 high	782K
Claude Code · Opus 5.5 h...	100%	Claude Code · Opus 5.5 h...	11분 19초	Claude Code · Opus 5.5 h...	745K
Codex · Daybreak Blue hi...	100%	Codex · Daybreak Blue hi...	21분 40초	Codex · Daybreak Blue hi...	961K

묶음 과제(2개) · 서로 다른 수정 두 개 한 번에

한 줄 요약: 같은 AI(Opus 5.5)를 쓸 때 CUELO는 Claude Code보다 시간 ▲ 10% 더 빠름, AI 사용량 ▼ 20% 더 씀, 정답률은 같음.

순위	도구 · AI 모델	정답 횟수	걸린 시간 (Claude Code 대비)	AI 사용량 (Claude Code 대비)	실제 요금
1	● CUELO · Opus 5.5 high	3/3 전부 정답	1분 53초 ▲ 10% 빠름	281K ▼ 20% 많음	\$0.98
2	● Claude Code · Opus 5.5 high	3/3 전부 정답	2분 5초	234K	\$0.84
3	● Codex · Daybreak Blue high	3/3 전부 정답	4분 4초 ▼ 95% 느림	240K = 비슷함	구독(정액)

정답률 — 길수록 좋음		걸린 시간 — 짧을수록 좋음		AI 사용량 — 짧을수록 좋음	
CUELO · Opus 5.5 high	100%	CUELO · Opus 5.5 high	1분 53초	CUELO · Opus 5.5 high	281K
Claude Code · Opus 5.5 h...	100%	Claude Code · Opus 5.5 h...	2분 5초	Claude Code · Opus 5.5 h...	234K
Codex · Daybreak Blue hi...	100%	Codex · Daybreak Blue hi...	4분 4초	Codex · Daybreak Blue hi...	240K

묶음 과제(3개) · 서로 다른 수정 세 개 한 번에

한 줄 요약: 같은 AI(Opus 5.5)를 쓸 때 CUELO는 Claude Code보다 시간 = 비슷함 , AI 사용량 ▼ 35% 더 싼 , 정답률은 같음.

순위	도구 · AI 모델	정답 횟수	걸린 시간 (Claude Code 대비)	AI 사용량 (Claude Code 대비)	실제 요금
1	● CUELO · Opus 5.5 high	3/3 전부 정답	6분 59초 = 비슷함	1.08M ▼ 35% 많음	\$3.12
2	● Claude Code · Opus 5.5 high	3/3 전부 정답	7분 11초	805K	\$2.48
3	● Codex · Daybreak Blue high	2/3 일부 실패	7분 42초 ▼ 7% 느림	619K ▲ 23% 적음	구독(정액)

정답률 — 길수록 좋음		걸린 시간 — 짧을수록 좋음		AI 사용량 — 짧을수록 좋음	
CUELO · Opus 5.5 high	100%	CUELO · Opus 5.5 high	6분 59초	CUELO · Opus 5.5 high	1.08M
Claude Code · Opus 5.5 h...	100%	Claude Code · Opus 5.5 h...	7분 11초	Claude Code · Opus 5.5 h...	805K
Codex · Daybreak Blue hi...	67%	Codex · Daybreak Blue hi...	7분 42초	Codex · Daybreak Blue hi...	619K

보통 과제 · 기존 기능 하나 고치기

순위	도구 · AI 모델	정답 횟수	걸린 시간 (Claude Code 대비)	AI 사용량 (Claude Code 대비)	실제 요금
1	● CUELO · Opus 5.5 medium	3/3 전부 정답	51초	119K	\$0.47
2	● Codex · GPT-6 Luna medium	3/3 전부 정답	1분 2초	56K	구독(정액)

정답률 — 길수록 좋음		걸린 시간 — 짧을수록 좋음		AI 사용량 — 짧을수록 좋음	
CUELO · Opus 5.5 medium	100%	CUELO · Opus 5.5 medium	51초	CUELO · Opus 5.5 medium	119K
Codex · GPT-6 Luna medi...	100%	Codex · GPT-6 Luna medi...	1분 2초	Codex · GPT-6 Luna medi...	56K

대규모 과제 · 스프레드시트 계산 엔진 새로 만들기

한 줄 요약: 같은 AI(Opus 5.5)를 쓸 때 CUELO는 Claude Code보다 시간 ▲ 10% 더 빠름 , AI 사용량 = 비슷함 , 맞힌 테스트 비율 CUELO 98.3% · Claude Code 97.5%.

순위	도구 · AI 모델	정답 횟수	걸린 시간 (Claude Code 대비)	AI 사용량 (Claude Code 대비)	실제 요금
1	Codex · Daybreak Blue high	0/2 테스트 99.3% 맞힘	12분 31초 ▼ 28% 느림	462K ▲ 34% 적음	구독(정액)
2	CUELO · Opus 5.5 high	0/2 테스트 98.3% 맞힘	8분 47초 ▲ 10% 빠름	666K = 비슷함	\$1.93
3	Claude Code · Opus 5.5 high	0/2 테스트 97.5% 맞힘	9분 48초	700K	\$2.10

맞힌 테스트 비율 — 길수록 좋음 (모두 만점은 못 받음)		걸린 시간 — 짧을수록 좋음		AI 사용량 — 짧을수록 좋음	
Codex · Daybreak Blue hi...	99.3%	Codex · Daybreak Blue hi...	12분 31초	Codex · Daybreak Blue hi...	462K
CUELO · Opus 5.5 high	98.3%	CUELO · Opus 5.5 high	8분 47초	CUELO · Opus 5.5 high	666K
Claude Code · Opus 5.5 h...	97.5%	Claude Code · Opus 5.5 h...	9분 48초	Claude Code · Opus 5.5 h...	700K

초대형 과제 · 서로 독립인 패키지 6개 새로 만들기

한 줄 요약: 같은 AI(Opus 5.5)를 쓸 때 CUELO는 Claude Code보다 시간 ▼ 53% 더 느림 , AI 사용량 ▲ 24% 덜 씀 , 정답률은 같음.

순위	도구 · AI 모델	정답 횟수	걸린 시간 (Claude Code 대비)	AI 사용량 (Claude Code 대비)	실제 요금
1	● CUELO · Opus 5.5 high	0/1 테스트 99.8% 맞힘	25분 2초 ▼ 53% 느림	2.43M ▲ 24% 적음	\$7.10
2	● Claude Code · Opus 5.5 high	0/1 테스트 99.5% 맞힘	16분 24초	3.21M	\$8.73
3	● Codex · Daybreak Blue high	0/1 테스트 98.5% 맞힘	25분 54초 ▼ 58% 느림	1.27M ▲ 60% 적음	구독(정액)

맞힌 테스트 비율 — 길수록 좋음 (모두 만점은 못 받음)		걸린 시간 — 짧을수록 좋음		AI 사용량 — 짧을수록 좋음	
CUELO · Opus 5.5 high	99.8%	CUELO · Opus 5.5 high	25분 2초	CUELO · Opus 5.5 high	2.43M
Claude Code · Opus 5.5 h...	99.5%	Claude Code · Opus 5.5 h...	16분 24초	Claude Code · Opus 5.5 h...	3.21M
Codex · Daybreak Blue hi...	98.5%	Codex · Daybreak Blue hi...	25분 54초	Codex · Daybreak Blue hi...	1.27M

메인 혼자 할 때 vs 전부 나눠 맡길 때

무엇을 비교했나: "메인 혼자"는 메인 AI가 하위 AI 없이 직접 구현한 경우다. 세 도구 모두 기록상 하위 AI를 쓰지 않았다(CUELO 대규모 6종 과제는 위임을 시도했으나 당시 설정 오류로 하위 AI 후보를 받지 못해 혼자 했다). "전부 위임"은 직접 고치지 말고 하위 AI(Maker-서브에이전트)에게 맡기라고 강제한 경우다. 비교 칩은 같은 도구의 메인 혼자 결과 대비다. Codex는 하위 AI의 사용량이 기록에 따로 나오지 않아 사용량이 실제보다 적게 잡혔을 수 있다. Claude Code는 실행 기록에 중간 도구 호출이 남지 않아 실제 위임 여부를 확인하지 못했다. Codex 보통 과제 위임 2회는 하위 AI 생성 오류(도구 자체 문제)로 코드를 전혀 고치지 못해 표에서 뺐다.

어려운 과제 · 안전 장치 새로 만들고 실제로 연결하기

도구 · 메인 모델	방식	정답	걸린 시간 (메인 혼자 대비)	AI 사용량 (메인 혼자 대비)
● CUELO · Opus 5.5 high	메인 혼자	6/6 전부 정답	7분 47초	782K
● Claude Code · Opus 5.5 high	메인 혼자	3/3 전부 정답	11분 19초	745K
● Codex · Daybreak Blue high	메인 혼자	3/3 전부 정답	21분 40초	961K
● CUELO · Opus 5.5 high	전부 위임 · GPT-6 Luna Maker	0/1 테스트 99.5% 맞힘	29분 59초 ▼ 286% 느림	2.97M ▼ 279% 많음
● Claude Code · Opus 5.5 high	전부 위임 · 자체 서브에이전트	1/2 일부 실패	21분 55초 ▼ 94% 느림	1.88M ▼ 152% 많음
● Codex · Daybreak Blue high	전부 위임 · 자체 서브에이전트	2/2 전부 정답	20분 2초 ▲ 8% 빠름	341K ▲ 65% 적음
● CUELO · Opus 5.5 high	전부 위임 · Opus 5.5 Maker	2/2 전부 정답	11분 37초 ▼ 49% 느림	1.50M ▼ 92% 많음

보통 과제 · 기존 기능 하나 고치기

도구 · 메인 모델	방식	정답	걸린 시간 (메인 혼자 대비)	AI 사용량 (메인 혼자 대비)
● CUELO · Opus 5.5 medium	메인 혼자	3/3 전부 정답	51초	119K
● Codex · GPT-6 Luna medium	메인 혼자	3/3 전부 정답	1분 2초	56K

도구 · 메인 모델	방식	정답	걸린 시간 (메인 혼자 대비)	AI 사용량 (메인 혼자 대비)
● CUELO · Opus 5.5 medium	전부 위임 · GPT-6 Luna Maker	2/2 전부 정답	4분 29초 ▼ 426% 느림	488K ▼ 310% 많음
● Claude Code · Opus 5.5 medium	전부 위임 · 자체 서브에이전트	2/2 전부 정답	1분 37초	147K
● CUELO · Opus 5.5 medium	전부 위임 · Opus 5.5 Maker	2/2 전부 정답	3분 51초 ▼ 352% 느림	586K ▼ 393% 많음

대규모 과제 · 스프레드시트 계산 엔진 새로 만들기

도구 · 메인 모델	방식	정답	걸린 시간 (메인 혼자 대비)	AI 사용량 (메인 혼자 대비)
● Claude Code · Opus 5.5 high	메인 혼자	0/2 테스트 97.5% 맞힘	9분 48초	700K
● Codex · Daybreak Blue high	메인 혼자	0/2 테스트 99.3% 맞힘	12분 31초	462K
● CUELO · Opus 5.5 high	메인 혼자	0/2 테스트 98.3% 맞힘	8분 47초	666K
● Claude Code · Opus 5.5 high	전부 위임 · 자체 서브에이전트	0/2 테스트 98.3% 맞힘	12분 18초 ▼ 25% 느림	861K ▼ 23% 많음
● Codex · Daybreak Blue high	전부 위임 · 자체 서브에이전트	0/2 테스트 99.0% 맞힘	20분 29초 ▼ 64% 느림	369K ▲ 20% 적음
● CUELO · Opus 5.5 high	전부 위임 · Opus 5.5 Maker	0/2 테스트 97.2% 맞힘	20분 11초 ▼ 130% 느림	2.86M ▼ 329% 많음

묶음 과제(3개) · 서로 다른 수정 세 개 한 번에

도구 · 메인 모델	방식	정답	걸린 시간 (메인 혼자 대비)	AI 사용량 (메인 혼자 대비)
● Claude Code · Opus 5.5 high	메인 혼자	3/3 전부 정답	7분 11초	805K
● Codex · Daybreak Blue high	메인 혼자	2/3 일부 실패	7분 42초	619K
● CUELO · Opus 5.5 high	메인 혼자	3/3 전부 정답	6분 59초	1.08M

도구 · 메인 모델	방식	정답	걸린 시간 (메인 혼자 대비)	AI 사용량 (메인 혼자 대비)
● CUELO · Opus 5.5 high	전부 위임 · Daybreak Blue Maker	1/2 일부 실패	20분 54초 ▼ 199% 느림	2.63M ▼ 142% 많음
● CUELO · Opus 5.5 high	전부 위임 · DeepSeek 4.1 Flash Maker	2/2 전부 정답	27분 27초 ▼ 293% 느림	5.22M ▼ 381% 많음
● CUELO · Opus 5.5 high	전부 위임 · GPT-6 Luna Maker	2/2 전부 정답	25분 4초 ▼ 259% 느림	2.76M ▼ 154% 많음
● CUELO · Opus 5.5 high	전부 위임 · Opus 5.5 Maker	2/2 전부 정답	9분 40초 ▼ 38% 느림	2.07M ▼ 91% 많음

초대형 과제 · 서로 독립인 패키지 6개 새로 만들기

도구 · 메인 모델	방식	정답	걸린 시간 (메인 혼자 대비)	AI 사용량 (메인 혼자 대비)
● Claude Code · Opus 5.5 high	메인 혼자	0/1 테스트 99.5% 맞힘	16분 24초	3.21M
● Codex · Daybreak Blue high	메인 혼자	0/1 테스트 98.5% 맞힘	25분 54초	1.27M
● CUELO · Opus 5.5 high	메인 혼자	0/1 테스트 99.8% 맞힘	25분 2초	2.43M
● Claude Code · Opus 5.5 high	전부 위임 · 자체 서브 에이전트	0/1 테스트 99.4% 맞힘	23분 45초 ▼ 45% 느림	4.47M ▼ 39% 많음
● Codex · Daybreak Blue high	전부 위임 · 자체 서브 에이전트	0/1 테스트 99.3% 맞힘	22분 57초 ▲ 11% 빠름	578K ▲ 55% 적음
● CUELO · Opus 5.5 high	전부 위임 · Opus 5.5 Maker	0/1 테스트 99.3% 맞힘	25분 39초 = 비슷함	5.08M ▼ 109% 많음

용어 풀이

AI 사용량

AI가 읽고 쓴 글자 양(토큰)을 요금 비중으로 환산한 값이다. 새로 읽은 양 + $0.1 \times$ 이미 기억해 둔 부분 다시 읽기 + $1.25 \times$ 기억해 두기 + $8 \times$ AI가 쓴 양. 비율은 가정값이다. 적을수록 싸다. 위임한 경우 하위 AI가 쓴 양도 합친다.

맞힌 테스트 (예: 958/960)

AI가 만든 프로그램을 검사하는 자동 채점 문항 수다. 문항 하나는 "이 입력을 넣으면 이 답이 나와야 한다" 같은 확인 한 가지다. 예를 들어 초대형 과제에는 문항이 960개 있고, 958/960은 960개 중 958개를 통과했다는 뜻이다. 문항은 AI가 작업 중에 볼 수 없게 숨겨 두었다가 끝난 뒤에만 돌렸다. 시험지를 미리 보지 못하게 한 채점이다.

정답 횟수

같은 과제를 여러 번(기본 3회, 위임·대규모는 2회) 돌려 채점 테스트를 모두 통과한 횟수.

Maker·서브에이전트

메인 AI가 일을 나눠 맡기는 하위 AI.

high / medium

AI에게 생각을 얼마나 깊게 시키는지 설정. high가 더 깊고 느리다.

구독(정액)

월정액 요금제로 써서 건별 요금이 따로 나오지 않는 경우.

자세히 보기 (측정 방법)

순위는 정답률 → 시간 → 사용량 순이다. 그래프의 가는 선은 최소~최대 범위다. CUELO 시간은 세션 유틸 대기를 뺀 실제 작업 시간이다. 과제 폴더의 규칙 파일은 모든 도구에서 숨겨 같은 조건을 맞췄다. 총 76회 실행.